

Presentación de Anteproyecto

Pregunta de investigación

Oscar Espinoza Gerardo Montero Gabriel Robles César Salazar

Section 1

Pregunta de investigación

¿Qué queremos responder?

La pregunta central del proyecto es:

¿Cuáles variables presentan mayor relevancia con la presencia de enfermedades cardiovasculares en la población analizada?

El proyecto busca identificar qué características demográficas, clínicas y de comportamiento muestran una relación más clara con la presencia de enfermedad cardiovascular dentro del dataset utilizado.

En particular, se analizan variables como:

- Edad
- Presión arterial sistólica y diastólica
- Índice de masa corporal
- Colesterol
- Glucosa
- Sexo
- Actividad física
- Tabaquismo

¿Para quién es relevante?

Esta pregunta es relevante para una audiencia actuarial, especialmente en áreas relacionadas con seguros de vida y salud, ya que la enfermedad cardiovascular representa un factor importante en la evaluación del riesgo individual y colectivo.

Desde una perspectiva actuarial, identificar variables asociadas con mayor riesgo cardiovascular puede aportar insumos para:

- Comprender mejor los perfiles de riesgo.
- Apoyar futuros modelos de tarificación.
- Mejorar procesos de segmentación de asegurados.
- Evaluar la pertinencia de ciertas variables clínicas en modelos de riesgo.

Además, el análisis también puede ser útil para una audiencia médica o de salud pública, ya que permite observar qué factores aparecen con mayor frecuencia asociados a pacientes con enfermedad cardiovascular.

Alcance de la investigación

La investigación tiene un alcance descriptivo y exploratorio.

Por lo tanto:

- Los resultados deben interpretarse como asociaciones observadas dentro del dataset.
- No se pretende establecer relaciones causales definitivas.
- El análisis busca identificar patrones estadísticos relevantes.
- Los hallazgos pueden servir como base para modelos predictivos futuros.

En este sentido, el proyecto busca generar evidencia descriptiva sobre los factores asociados con enfermedad cardiovascular, reconociendo las limitaciones inherentes a los datos observacionales.

Section 2

Datos

Fuente de datos

El análisis utiliza el dataset `cardio_train.csv`, una base de datos con información clínica, demográfica y de comportamiento relacionada con enfermedades cardiovasculares.

Cada fila representa un paciente y cada columna corresponde a una variable asociada al riesgo cardiovascular.

El dataset incluye variables como:

- Edad
- Presión arterial sistólica y diastólica
- Índice de masa corporal (IMC)
- Colesterol
- Glucosa
- Sexo
- Actividad física
- Consumo de alcohol
- Tabaquismo

Tamaño y estructura de los datos

- Aproximadamente 70 000 observaciones
- 13 variables principales
- Datos en formato tidy
- Variable respuesta balanceada:
 - Presencia de enfermedad cardiovascular
 - Ausencia de enfermedad cardiovascular

No se encontraron valores faltantes significativos, por lo que no fue necesario realizar imputación de datos.

Limitaciones de los datos

- El dataset no especifica claramente su origen geográfico.
- No incluye variables como:
 - antecedentes familiares,
 - genética,
 - tratamientos médicos,
 - dieta.
- Los resultados representan asociaciones observadas y no causalidad.
- La validez externa del análisis puede ser limitada.

Análisis exploratorio de datos (AED)

El análisis exploratorio mostró que las variables más asociadas con enfermedad cardiovascular son:

- Edad
- Presión arterial sistólica
- Índice de masa corporal

También se observaron patrones importantes:

- Pacientes con enfermedad cardiovascular tienden a tener mayor edad.
- La hipertensión presenta una relación clara con enfermedad cardiovascular.
- Niveles altos de colesterol y glucosa concentran mayor proporción de pacientes con enfermedad cardiovascular.

Hallazgos principales del AED

- La presión arterial sistólica fue la variable con mayor asociación observada.
- El colesterol mostró una correlación menor a la esperada.
- El IMC presentó distribuciones ligeramente mayores en pacientes cardiovasculares.
- La base de datos no presentó problemas importantes de calidad.

Section 3

Metodología

Intervalos Bayesianos

- Comparar intervalos bayesianos en grupos de individuos
- Ejemplo: media de edad con y sin enfermedad
- Cómo se intersecan
- Cómo difieren
- Usando gráficos como apoyo

¿Por qué Intervalos Bayesianos?

- Estado del arte
- Gill et al (Why clinicians are natural Bayesians)
- Poca cantidad de datos
- Gran cantidad de factores (dimensiones reducidas)
- Ventajas predicción bayesiana
- Alternativa: modelo frecuentista

Section 4

Resultados esperados

¿Qué esperamos encontrar?

Se espera encontrar cuáles variables, como la presión arterial sistólica, la edad, el IMC, el colesterol etc., presentan una asociación estadísticamente significativa en la presencia de enfermedades cardiovasculares. Desde el enfoque bayesiano, se obtendrán distribuciones posteriores para los parámetros de interés, permitiendo construir intervalos de credibilidad al 95% para la probabilidad de enfermedad cardiovascular según cada factor de riesgo.

¿Cómo sabremos si la pregunta quedó respondida?

Como criterio de respuesta a la pregunta de investigación, Se considerará que un factor es relevante si la diferencia entre las medias posteriores de las probabilidades de los dos grupos comparados es sustantiva en términos prácticos, y si sus intervalos de credibilidad al 95% no se solapan. También se realizará un análisis de sensibilidad a la distribución previa para evaluar la robustez de las conclusiones, dicho análisis se podría hacer comparando tres distribuciones previas (no informativa, ligeramente informativa e informativa) para verificar que las estimaciones posteriores no dependen sustancialmente de la elección de la prior.