Bitácora #1

CA-0303 Estadística Actuarial I

Oscar Espinoza, Gerardo Montero, Gabriel Robles, César Salazar

2026-04-06

Tabla de contenidos

1 Planificación **3**
1.1 Pregunta de investigación . . . 3
1.1.1 Definición de la idea . . . 3
1.1.2 Conceptualización de la idea . . . 3
1.1.3 Identificación de tensiones . . . 4
1.1.4 Reformulación de la idea en forma de pregunta . . . 4
1.1.5 Argumentación de la pregunta . . . 4
1.1.6 Argumentación a través de datos . . . 8
1.2 Revisión bibliográfica . . . 11
1.3 Ficha de Literatura 1 . . . 14
1.3.1 Nivel descriptivo . . . 14
1.3.2 Nivel analítico . . . 15
1.4 Ficha de Literatura 2 . . . 16
1.4.1 Nivel descriptivo . . . 16
1.4.2 Nivel analítico . . . 17
1.5 Ficha de Literatura 3 . . . 18
1.5.1 Nivel descriptivo . . . 18
1.5.2 Nivel analítico . . . 19
1.6 UVE de Gowin . . . 20
1.7 Parte de escritura . . . 20
1.8 Arco narrativo del proyecto . . . 22
1.9 Diario de aprendizaje . . . 22
1.10 Rastro de decisiones . . . 22
1.10.1 Decisión 1: Uso del *dataset* . . . 22
1.10.2 Decisión 2: Enfoque del proyecto . . . 23
1.10.3 Decisión 3: Selección de la pregunta de investigación . . . 23

1.11 Registro de uso de IA 24
1.11.1 Consulta: Redacción audiencia y posicionamiento 24
1.11.2 Consulta: Revisión de preguntas de investigación y tensiones 24
1.11.3 Consulta: Preguntas de lógica, ética y emocional 25
1.11.4 Consulta: Revisión de la sección 1.1.6 25
1.11.5 Consulta: Apoyo en el formato de la ficha de D'Agostino et al. (2013) . 26
1.11.6 Consulta: Apoyo en el formato de la ficha de Damen et al. (2016) 27
1.11.7 Consulta: Revisión Bibliográfica 27
1.11.8 Consulta: Consulta sobre UVE de Gowin 28
1.12 Marco teórico 28
1.13 Log de contribuciones 30
1.14 Referencias 30

Bitácora #1

Audiencia del proyecto

"Esta semana, le diría a un actuario de seguros médico o de vida que las enfermedades cardiovasculares representan uno de los riesgos más significativos que enfrenta su cartera de asegurados, y que contar con un análisis estadístico riguroso de sus factores predictores podría mejorar la precisión en la estimación de primas y la gestión del riesgo."

La audiencia de este proyecto es el actuario especializado en seguros de vida o seguros de salud. Las enfermedades cardíacas constituyen una de las principales causas de mortalidad a nivel mundial, lo que las convierte en un factor determinante al momento de estimar el riesgo de vida de un asegurado. Al identificar qué características clínicas y físicas están más asociadas con la presencia de enfermedades cardiovasculares, un actuario puede incorporar esa información al proceso de suscripción y tarifación: ajustar la prima según el perfil de riesgo del cliente, establecer exclusiones pertinentes o diseñar productos más precisos. Este proyecto busca, entonces, proveerle a ese profesional una base estadística que respalde sus decisiones con evidencia.

Posicionamiento del equipo

El equipo está conformado por estudiantes de Ciencias Actuariales, se aborda este proyecto desde una perspectiva directamente alineada con su aplicación profesional, la gestión del riesgo

en seguros de vida y salud. Un integrante cuenta con experiencia en pasantía desarrollando aplicaciones de visualización de datos con Shiny usando información real de la Superintendencia de Pensiones, lo que aporta familiaridad con datos institucionales y herramientas de análisis en R. Otro integrante se desempeña en una operadora de pensiones complementarias, liderando análisis financiero y de datos aplicado a la evaluación de instrumentos y vehículos de inversión. Su trabajo integra modelación cuantitativa, análisis cualitativo y desarrollo de soluciones analíticas, lo que le permite generar insights sobre el comportamiento de los activos y mantener un vínculo directo con el entorno financiero regulado costarricense. Estas experiencias, combinadas con la formación actuarial compartida por todos los integrantes, nos posicionan para abordar este problema desde una perspectiva tanto técnica como aplicada.

1 Planificación

1.1 Pregunta de investigación

1.1.1 Definición de la idea

Idea: **"Se quiere identificar las características en las personas que más influyen en enfermedades cardíacas**

1.1.2 Conceptualización de la idea

De la idea anterior, se definen las palabras clave según la Real Academia Española (2026):

Característica: Cualidad que da carácter o sirve para distinguir a alguien o algo de sus semejantes.

Influir: Dicho de una cosa: Producir sobre otra ciertos efectos; como el hierro sobre la aguja imantada, la luz sobre la vegetación, etc.

Además, se define según la World Heart Federation (2023):

Enfermedades Cardiovasculares: Enfermedades que afectan al corazón o a los vasos sanguíneos (venas y arterias). Pueden estar causadas por una combinación de factores de riesgo socioeconómicos, conductuales y ambientales, como hipertensión arterial, dieta poco saludable, colesterol alto, diabetes, contaminación atmosférica, obesidad, tabaquismo, enfermedades renales, inactividad física, consumo nocivo de alcohol y estrés. *Los antecedentes familiares, el origen étnico, el sexo y la edad* también pueden afectar al riesgo de enfermedad cardiovascular de una persona.

1.1.3 Identificación de tensiones

1. Puede que el tamaño de la muestra no sen suficiente para concluir estadísticamente acerca de la influencia de ciertas variables en la presencia de enfermedades cardíacas.
2. Es posible que los valores de las variables estén muy dispersos y no se note una clara distinción en cuál variable influye realmente en tener la la presencia de alguna enfermedad cardíaca.
3. Según la WHF, son variables relevantes los antecedentes familiares y el origen étnico al momento de evaluar la posibilidad de tener problemas cardíacos, la ausencia de estas variables en el *dataset* limita el alcance explicativo del análisis.

1.1.4 Reformulación de la idea en forma de pregunta

1. ¿Qué importancia tiene conocer la influencia de ciertas características de personas en enfermedades cardíacas?
2. ¿Cómo influyen ciertas características de personas en enfermedades cardíacas?
3. ¿Cuáles son las características en personas que más influyen en enfermedades cardíacas?
4. ¿Qué patrones presentan estas características en personas con y sin enfermedades cardíacas?

Se descarta la pregunta 1, pues la importancia es muy bien conocida, pues al conocer dichas características se puede prevenir la presencia de enfermedades cardiovasculares, además de que dicha importancia no se puede medir con los datos encontrados. De igual forma con la pregunta 2 con los mismos datos no es posible entender exactamente cómo influyen estas características en la aparición de estas enfermedades, por lo que se descarta su estudio. Finalmente se descarta la pregunta 4, pues se requieren de muchas herramientas fuera del alcance del curso para analizar completamente los patrones que existen en los datos utilizados, por lo que se decide trabajar con la pregunta 3, además de que esta última pregunta explica mejor la idea inicialmente expuesta.

1.1.5 Argumentación de la pregunta

*__Pregunta 1__ ¿Qué importancia tiene conocer la influencia de ciertas características de personas en enfermedades cardíacas?

1.1.5.1 Contraargumentos

Lógica:
Conocer la importancia de estas características no necesariamente implica poder predecir o prevenir la enfermedad, ya que pueden existir variables ocultas o factores no medidos en el *dataset*.

Ética:
El uso de datos médicos puede generar interpretaciones incorrectas si no se consideran contextos clínicos adecuados, lo que podría llevar a conclusiones irresponsables.

Emocional:
La difusión de resultados sobre factores de riesgo puede generar ansiedad en las personas si se interpretan como determinantes absolutos de la enfermedad.

1.1.5.2 Argumentos

Lógica:
El análisis de variables como edad, colesterol y presión arterial permite identificar patrones asociados a enfermedades cardíacas, lo cual es fundamental en estudios poblacionales de la salud.

Ética:
Trabajar con datos anónimos y públicos permite realizar análisis responsables sin comprometer la privacidad de las personas.

Emocional:
El conocimiento de factores de riesgo puede benerficiar a las personas para adoptar hábitos más saludables y tomar decisiones informadas sobre su salud.

1.1.5.3 Conclusión

Conocer la influencia de ciertas características en enfermedades cardíacas es fundamental para la prevención y comprensión del problema. Aunque existen limitaciones en los datos y posibles interpretaciones erróneas, el valor informativo de este análisis justifica su estudio, especialmente en contextos donde la prevención es clave.

Pregunta 2

¿Cómo influyen ciertas características de personas en enfermedades cardíacas?

1.1.5.4 Contraargumentos

Lógica:
Los datos disponibles permiten identificar correlaciones, pero no necesariamente relaciones causales, lo que limita la interpretación de cómo influyen realmente las variables.

Ética:
La simplificación de la influencia de variables podría llevar a conclusiones reduccionistas, ignorando factores sociales, genéticos o ambientales no incluidos en el *dataset*, por la diversidad de posibilidades.

Emocional:
Las personas podrían asumir que ciertas características determinan su condición de salud, lo que puede generar fatalismo o decisiones equivocadas.

1.1.5.5 Argumentos

Lógica:
A través de métodos estadísticos como regresión o análisis de correlación, es posible identificar el grado de asociación entre variables y la presencia de enfermedades cardíacas.

Ética:
El uso de datos estructurados y documentados permite realizar análisis transparentes y replicables, garantizando la integridad del estudio.

Emocional:
Comprender cómo influyen las variables permite comunicar mejor los riesgos y fomentar cambios positivos en el estilo de vida de las personas.

1.1.5.6 Conclusión

Si bien los datos no permiten establecer causalidad directa, sí es posible analizar cómo influyen ciertas características en enfermedades cardíacas mediante relaciones estadísticas. Este enfoque aporta valor al entendimiento del problema, siempre que se interprete con cautela y dentro de sus limitaciones.

Pregunta 3 ¿Cuáles son las características en personas que más influyen en enfermedades cardíacas?

1.1.5.7 Contraargumentos

Lógica:
La identificación de las características más influyentes depende del método utilizado, lo que puede generar resultados distintos y dificultar determinar cuáles variables son realmente las más relevantes.

Ética:
El *dataset* puede no ser representativo de toda la población, lo que introduce sesgos en los resultados.

Emocional:
Las personas podrían interpretar erróneamente los resultados y generar preocupación innecesaria sobre su salud.

1.1.5.8 Argumentos

Lógica:
Mediante análisis estadísticos como correlación y modelos de clasificación, es posible identificar variables con mayor peso en la predicción de enfermedades cardíacas de acuerdo a los datos.

Ética:
El uso de datos públicos y anónimos provenientes de sitios conocidos por ser usados para bases de datos, como es el caso de kaggle, garantiza que no se vulnera la privacidad de los individuos.

Emocional:
El análisis puede contribuir a la concientización sobre factores de riesgo y promover hábitos saludables.

1.1.5.9 Conclusión

El análisis de las características más influyentes en enfermedades cardíacas es viable mediante herramientas estadísticas y de aprendizaje automático. Sin embargo, los resultados deben interpretarse con cautela debido a posibles sesgos y a la naturaleza no causal de los datos. Aun así, este estudio puede aportar valor en la identificación de factores de riesgo relevantes.

Pregunta 4

¿Qué patrones presentan estas características en personas con y sin enfermedades cardíacas?

1.1.5.10 Contraargumentos

Lógica: El análisis de patrones puede verse limitado por la dispersión de los datos, lo que dificulta identificar diferencias claras entre personas con y sin enfermedades cardíacas.

Ética: El *dataset* no incluye todas las variables relevantes (como antecedentes familiares o factores genéticos), lo que puede generar interpretaciones incompletas o sesgadas.

Emocional: Las personas podrían interpretar los patrones como determinantes absolutos de su salud, generando preocupación innecesaria o conclusiones erróneas.

1.1.5.11 Argumentos

Lógica: El *dataset* permite dividir la población en dos grupos (con y sin enfermedad cardiovascular) y analizar diferencias en variables como edad, presión arterial, colesterol y hábitos de vida, lo que facilita la identificación de patrones característicos en cada grupo.

Ética: El uso de datos anónimos y públicos permite realizar análisis responsables sin comprometer la privacidad de los individuos, siempre que se interpreten los resultados con cautela.

Emocional: Identificar patrones puede ayudar a generar conciencia sobre factores asociados a enfermedades cardíacas, incentivando hábitos saludables y una mayor atención a la salud personal.

1.1.5.12 Conclusión

El análisis de patrones entre personas con y sin enfermedades cardíacas es viable con los datos disponibles y aporta una perspectiva descriptiva importante para el proyecto. Aunque existen limitaciones en el *dataset*, este enfoque permite complementar la pregunta principal y contribuir al entendimiento del problema desde un análisis exploratorio.

1.1.6 Argumentación a través de datos

El conjunto de datos utilizado en este proyecto corresponde a un *dataset* clínico orientado al estudio de enfermedades cardiovasculares, conocido como **"Cardiovascular Disease *dataset*" (cardio_train.csv)**. Este tipo de información es ampliamente utilizado en estudios estadísticos y de aprendizaje automático para analizar factores de riesgo asociados a condiciones cardíacas.

1.1.6.1 Fuente de los datos

El *dataset* proviene de una base de datos pública disponible en la plataforma Kaggle por Ulianova (2019) construida a partir de registros médicos anónimos. Su uso es frecuente en contextos académicos debido a la variedad de variables clínicas y de estilo de vida que contiene.

1.1.6.2 Contexto temporal y espacial

El *dataset* no especifica de manera explícita el periodo de recolección ni la ubicación geográfica exacta de los pacientes. Esta limitación tiene implicaciones directas para nuestra pregunta de investigación: los factores de riesgo cardiovascular pueden variar significativamente entre poblaciones de distintas regiones geográficas y épocas, por lo que los patrones identificados en este *dataset* podrían no generalizarse a otras poblaciones. En consecuencia, los resultados del análisis deben interpretarse como asociaciones válidas dentro del contexto de esta muestra específica, sin asumir representatividad global. Se asume que los datos provienen de un entorno clínico estructurado, lo que garantiza cierta consistencia en las mediciones.

1.1.6.3 Facilidad de obtención de la información

El *dataset* es de acceso público y gratuito, disponible en la plataforma Kaggle. Puede descargarse directamente en formato CSV, lo que facilita su manipulación en herramientas estadísticas como R o Python. No requiere permisos especiales ni procesos complejos de adquisición.

1.1.6.4 Población de estudio

La población corresponde a pacientes adultos evaluados mediante diferentes mediciones clínicas. No se cuenta con información específica del país o institución de origen, pero se asume que los datos provienen de un entorno médico controlado.

1.1.6.5 Muestra observada

El conjunto de datos está compuesto por aproximadamente 70,000 registros de pacientes. Cada uno corresponde a una observación individual, lo que permite trabajar con un tamaño de muestra suficientemente grande para realizar análisis estadísticos confiables.

1.1.6.6 Unidad estadística

La unidad estadística es cada paciente individual registrado en el *dataset*. Cada fila representa una observación independiente con sus respectivas características médicas y hábitos.

1.1.6.7 Estructura de la tabla de datos

Cada fila del *dataset* representa un paciente individual. Cada columna corresponde a una variable específica que describe alguna característica del paciente, ya sea demográfica, fisiológica, bioquímica o de comportamiento. Cada celda contiene el valor observado de esa variable para un paciente determinado. Por ejemplo, la celda en la columna de presión arterial sistólica para una fila dada indica la medición exacta de ese paciente en ese indicador, lo cual es uno de los valores que el modelo utilizará para determinar si ese paciente presenta o no enfermedad cardiovascular.

1.1.6.8 Variables del *dataset* y su relación con la pregunta de investigación

El conjunto de datos incluye variables tanto cuantitativas como cualitativas. A continuación se describen y se explica su relevancia para la pregunta de investigación.

Variables demográficas:

- *Edad (en días):* Representa la edad del paciente al momento del registro. Para el análisis se transformará a años dividiendo entre 365, lo cual facilita la interpretación. La edad es un factor de riesgo cardiovascular ampliamente documentado: a mayor edad, mayor probabilidad de desarrollar enfermedades del corazón, por lo que esta variable es central en nuestro argumento.
- *Género:* Variable categórica que permite explorar si existen diferencias estadísticamente significativas en la prevalencia de enfermedades cardiovasculares entre hombres y mujeres, lo cual es relevante para caracterizar la población en riesgo.

Variables fisiológicas:

- *Altura y peso:* Permiten calcular el Índice de Masa Corporal (IMC), un indicador del estado nutricional del paciente. El sobrepeso y la obesidad son factores de riesgo cardiovascular reconocidos, por lo que estas variables contribuyen directamente a argumentar la relación entre composición corporal y enfermedad.
- *Presión arterial sistólica y diastólica:* Son variables centrales para el análisis. La hipertensión es uno de los factores de riesgo cardiovascular más documentados en la literatura médica. Su presencia en el *dataset* permite explorar directamente la asociación estadística entre niveles de presión arterial y la variable respuesta.

Variables bioquímicas:

- *Nivel de colesterol:* Variable categórica ordinal (normal, por encima de lo normal, muy por encima de lo normal). El colesterol elevado está asociado a la acumulación de placas en las arterias, lo que incrementa el riesgo de enfermedades cardiovasculares. Esta variable permite argumentar el efecto de los marcadores bioquímicos en el diagnóstico.
- *Nivel de glucosa:* Similar al colesterol, permite explorar la relación entre niveles de azúcar en sangre y la presencia de enfermedad cardiovascular, lo cual es especialmente relevante considerando la asociación entre diabetes y riesgo cardíaco.

Variables de comportamiento:

- *Consumo de alcohol, hábito de fumar y nivel de actividad física:* Estas variables categóricas binarias capturan los hábitos de vida del paciente. Su inclusión permite argumentar que los factores de estilo de vida, además de los fisiológicos y bioquímicos, tienen un rol en la probabilidad de desarrollar enfermedades cardiovasculares. Son variables que conectan emocionalmente con el lector, ya que representan decisiones que cualquier persona puede modificar.

Variable respuesta:

- *Presencia o ausencia de enfermedad cardiovascular:* Variable binaria (0 = ausencia, 1 = presencia). Es la variable que se busca explicar y predecir a partir de todas las anteriores. Su naturaleza dicotómica determina el tipo de técnicas estadísticas a aplicar, como regresión logística u otros modelos de clasificación.

1.1.6.9 Naturaleza de los datos

Los datos son de tipo **observacional**, ya que no provienen de un experimento controlado sino de registros existentes. Esto implica que las relaciones encontradas entre variables deben interpretarse como asociaciones y no necesariamente como causalidad. El *dataset* contiene variables discretas, continuas y categóricas, lo cual lo hace adecuado para aplicar diversas técnicas estadísticas vistas en el curso.

1.1.6.10 Relevancia para el proyecto

Este *dataset* es pertinente porque permite analizar de forma integral cómo factores demográficos, fisiológicos, bioquímicos y de comportamiento se asocian con la probabilidad de desarrollar enfermedades cardiovasculares. La diversidad de variables facilita abordar la pregunta de investigación desde múltiples ángulos, aplicando herramientas como análisis descriptivo, exploración de relaciones entre variables y modelado predictivo, alineándose directamente con los objetivos del curso.

1.2 Revisión bibliográfica

Sobre el tema de los problemas cardiovasculares en el ambiente de la estadística se ha escrito una gran cantidad de artículos. Entre ellos, uno de los más destacados es la obra de Gill et al. (2005) *Why Clinitians are natural Bayesians*; que a pesar de la edad del artículo, provee detalles de por qué el enfoque bayesianoes mejor usarse en lugar del enfoque clásico. De acuerdo a Gill et al. (2005) "El enfoque bayesiano no devuelve una respuesta de sí o no, sino una probabilidad condicional que refleja el contexto en el que el se hace la prueba". Por lo tanto, el enfoque bayesiano tiene la ventaja de que el contexto cambia las conclusiones que se pueden extraer para los datos. La diferencia entre estos dos se va a profundizar aún más en el marco teórico de esta investigación, pero este artículo es fundamental para comprender por qué se usa el enfoque bayesiano sobre el clásico o frecuentista.

Además de este artículo, hay más que explican por qué se prefiere el enfoque bayesiano para datos como estos. Entre estos, el articulo de Lorca & Águila (2024) *Inferencia Bayesiana en el proceso de diagnóstico clínico: un enfoque docente para la toma de decisiones* es una obra mucho más reciente que la anterior, en particular algo llamativo es su metodología, pues usan una modificación del Teorema de Bayes:

Cuadro 1. Componentes de la ecuación derivada del teorema de Bayes

***Odds* post-test de enfermedad**	***Likelihood ratio* o Factor de Bayes**	***Odds* pre-test de enfermedad**
$\frac{P(E+\|T)}{P(E-\|T)}$	$\frac{P(T\|E+)}{P(T\|E-)}$	$\frac{P(E+)}{P(E-)}$
Se refiere al *odds* de presentar la enfermedad en comparación con no presentarla, dado el resultado de una prueba diagnóstica. Este valor se denomina *odds post-test* de enfermedad y corresponde al paso n°3 del proceso de diagnóstico clínico.	Se refiere al *odds* de obtener un determinado resultado en una prueba diagnóstica en un paciente con la enfermedad, en comparación con obtener dicho resultado en un paciente sin la enfermedad. La certeza de tener o no la enfermedad proviene de la aplicación de un estándar de oro. Este valor se denomina *likelihood ratio* o Factor de Bayes y representa la información que aporta la prueba diagnóstica en el paso n°2 del proceso de diagnóstico clínico.	Corresponde al *odds* de que un paciente presente una enfermedad, versus no presentarla, previo a conocer el resultado de la prueba diagnóstica. Recibe el nombre de *odds pre-test* de enfermedad y se plantea inicialmente frente a un paciente, en base a la información preliminar que se recaba en el paso n°1 del proceso de diagnóstico clínico. Su valor a menudo se homologa a la prevalencia de la enfermedad en la población.

Figura 1: Figura 1.2.1.1: Metodología de Lorca & Águila (2024)

El uso del factor de Bayes como un cociente de probabilidades condicionales entre eventos similares pero opuestos en cómo se condicionan provee información importante para la metodología que se podrá usar en la investigación.

Otro artículo que es similar al anterior es *Una pequeña mirada a la estadística bayesiana en el análisis de datos cardiológicos* por Armero et al. (2022). Esto se da gracias a que la metodología de este también hace uso del teorema de Bayes para construir un factor de Bayes. En particular, además demuestra como se puede incorporar información de estudios previos y manejar muestras pequeñas o datos complejos, lo cual es una tendencia común en otros artículos referenciados en esta sección.

The Information Theoretic Perspective on Medical Diagnostic Inference por Eiseman et al. (2014), donde se provee una tabla útil para ver cómo definieron su factor de Bayes

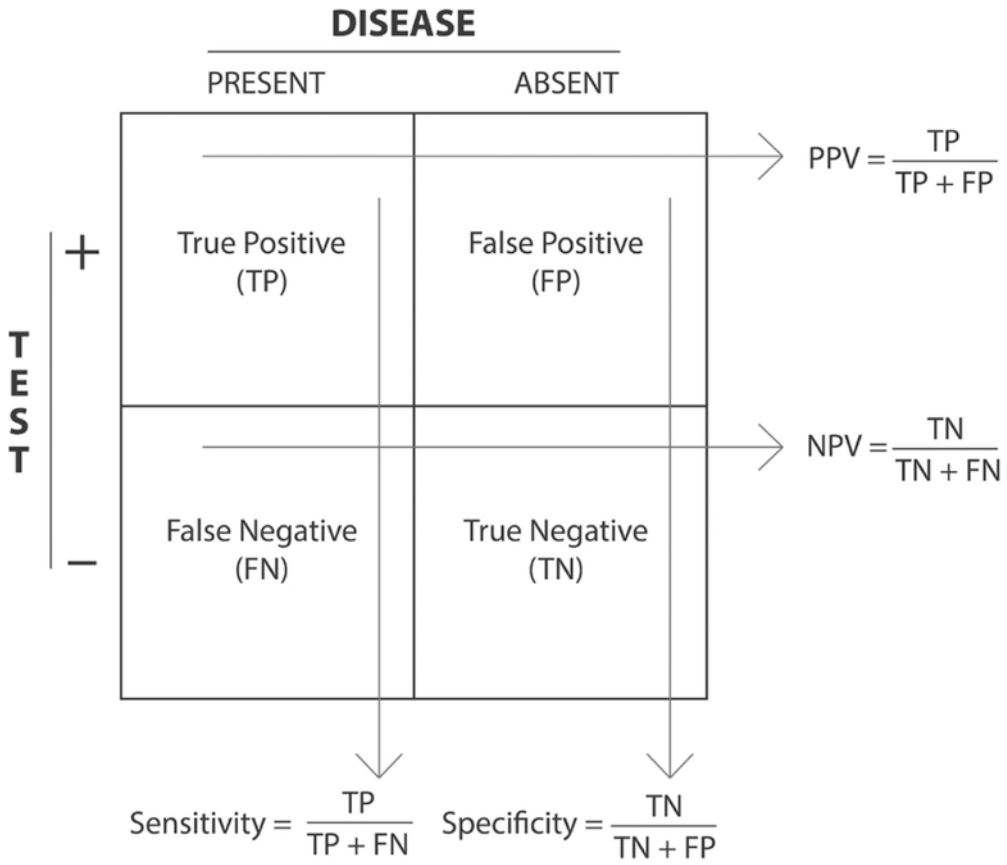

El factor de Bayes en este caso varía un poco comparado a los otros pero la idea general se basa en tomar una probabilidad basada en el Teorema de Bayes, usando ocurrencias falsas y verdaderas del padecimiento. Este enfoque complementa la estadística bayesiana al medir cuánta "información" aporta realmente un biomarcador o un signo clínico en el proceso diagnóstico.

El factor de Bayes como metodología se cubre también ampliamente en la obra de Ramos-Vera (2021) *El uso del factor Bayes en la investigación clínica de cardiología*. En particular,

empieza explicando por qué el factor de bayes es usado en la cardiología. Pues, como indica las investigaciónes clínicas ocupan evidencia con la mayor credibilidad posible, pero se complica por la poca cantidad de eventos. En su caso, usan el factor de Bayes como una probabilidad de los datos frente una hipóteis nula frente a hipótesis alternativa. Resumido, considera que el Factor de Bayes permite conclusiones más sólidas en los estudios de cardiología.

Aparte de aplicaciones directas de la estadística para la cardiología, también hay artículos que se basan en modelos predictivos. El más reciente de este es el artículo de Kaufmann et al. (2019) *A Bayesian Network Analysis of the Diagnostic Process and its Accuracy to Determine How Clinicians Estimate Cardiac Function in Critically Ill Patients: Prospective Observational Cohort Study*. En este artículo definien una función que dependen de probabilidades condicionales, cuyas condiciones en sí son dependientes de varios factores de riesgo. Lo particular de este artículo es su uso de redes bayesianes. Realiza un estudio de cohorte prospectivo utilizando redes bayesianas para modelar cómo los médicos estiman la función cardíaca en pacientes críticos. El estudio identifica dependencias clave, como el uso de noradrenalina y el llenado capilar, revelando que el juicio clínico a menudo es poco preciso y puede mejorarse mediante herramientas digitales de entrenamiento basadas en probabilidades.

Siguiendo con el tema de modelos predictivos, la obra de Damen et al. (2016) *Prediction models for cardiovascular disease risk in the general population: systematic review* se destaca entre las otras pues se enfoca menos en el ámbito teórico y empieza a aplicarlo a datos reales; en particular, más de 100 modelos. En los modelos analizados en el estudio, los más importantes fueron sexo: que se incluyeron en 24% de los estudios pero 88% de esos modelos se enfocaron en solo uno de los sexos. 66% de esos incluyeron predictores que consistían edad, fumador, presión de sangre y colesterol. 52% incluían diabetes, 29% incluían índice de masa corporal y sólamente 15% incluían el uso de tratamiento (ie drogas contra hypertension, etc.). Una limitación de este artículo, a pesar de su gran versatilidad es la alta variabilidad de muestras, con un mínimo de 51 en un modelo y un máximo de 1.189.845 en otro (mediana de 3969). Además, la cantidad de eventos también varía mucho: de 28 a 55.667. Critica la proliferación de nuevos modelos que a menudo carecen de validación externa y resalta la importancia de la metodología estadística rigurosa para asegurar que estas herramientas sean útiles y no introduzcan sesgos en la prevención cardiovascular

Cardiología "basada en la evidencia": aplicaciones prácticas de la epidemiología. IV. Modelos de predicción de riesgo cardiovascular por Rodríguez-Escudero et al. (2012) provee otro punto de vista en los modelos predictivos. En particular, considera el factor de riesgo más importante como la edad. Esto es gracias a que la supervivencia edad en sí sigue una distribución exponencial, entonces el riesgo cardiovascular también se ve afectado. El segundo factor de riesgo, es el sexo por razones similares a la edad, el hombre tiende a tener una expectativa de vida menor a la mujer. Para ilustrar esto, compara un caso de una mujer de 50 años y un hombre de 50 años. Analiza cómo las variables estadísticas se transforman en herramientas de puntuación clínica para predecir eventos futuros, subrayando la necesidad de que estos modelos se adapten a las poblaciones específicas donde se aplican

Finalmente, para complementar la bibliografía existente, se van a utilizar varias obras para definir conceptos teóricos centrales a la investigación. Para explicar la diferencia entre inferencia bayesiana y clásica, la obra de Pek & Van Zandt (2019) *Frequentist and Bayesian approaches to to data analysis: Evaluation and estimation*. Esta explica la diferencia entre ambos con simplicidad, pero también provee ejemplos que ilustran cómo diferentes conclusiones se pueden extraer de los mismos datos a partir de los dos enfoques. Para conceptos de estadística, el libro de DeGroot & Schrevish (2012) *Probability & Statistics* provee definiciones amplias para conceptos necesarios para explicar la inferencia bayesiana y clásica.

1.3 Ficha de Literatura 1

1.3.1 Nivel descriptivo

Título: Cardiovascular Disease Risk Assessment: Insights from Framingham

Autor(es): Agostino, R. B. Sr.; Pencina, M. J.; Massaro, J. M.; Coady, S.

Año: 2013

Nombre del tema: Desarrollo, evaluación y validación de funciones multivariables de riesgo cardiovascular derivadas del Estudio Framingham.

Clasificación: *Metodológica* — se eligió esta etiqueta porque el documento se centra en los métodos estadísticos (modelo de Cox, calibración, discriminación) para construir y validar modelos de predicción, y no en describir el fenómeno cardiovascular en sí (temática), en ordenar el conocimiento históricamente (cronológica) ni en proponer un marco conceptual nuevo (teórica).

Resumen en una oración: Funciones multivariables de Framingham estiman riesgo cardiovascular combinando factores clínicos mediante modelos estadísticos.

Argumento central: La enfermedad cardiovascular es multifactorial, por lo que ningún factor de riesgo aislado es suficiente para evaluarla. Las Framingham Risk Functions combinan variables como edad, presión arterial sistólica, colesterol total, colesterol HDL, tabaquismo y diabetes en un modelo de Cox que produce estimaciones de riesgo absoluto a 10 años, con buena discriminación (C-estadístico entre 0.79 y 0.83) y calibración tanto en la muestra original como en poblaciones externas tras recalibración.

Problemas con el argumento o el tema: Los autores reconocen que las funciones fueron desarrolladas en una población blanca de clase media de Massachusetts, lo que limita su generalización directa a otras etnias o regiones; en poblaciones asiáticas e hispanas el modelo sobreestima el riesgo sin recalibración previa. Además, una vez que el C-estadístico supera 0.75 es matemáticamente muy difícil mejorarlo añadiendo nuevos biomarcadores, lo que representa un techo de predicción inherente a estos modelos.

1.3.2 Nivel analítico

Conexión con mi proyecto: Este artículo respalda directamente nuestra pregunta de investigación porque valida el uso de variables como presión arterial sistólica, colesterol, glucosa, tabaquismo y edad —todas presentes en nuestro *dataset* `cardio_train.csv`— como predictores relevantes de enfermedad cardiovascular. Además, justifica metodológicamente el uso de regresión logística y modelos de clasificación binaria sobre nuestra variable respuesta binaria (presencia/ausencia de ECV), y provee criterios concretos para evaluar su desempeño: el C-estadístico y el test de calibración de Nam-D'Agostino.

Lo que NO dice el autor: El artículo no aborda el rendimiento predictivo cuando se incluyen variables de comportamiento como consumo de alcohol o nivel de actividad física junto a los marcadores clínicos clásicos, dimensión que nuestro *dataset* sí permite explorar. Tampoco discute el impacto de trabajar con datos sin contexto geográfico definido, limitación que afecta directamente a `cardio_train.csv`.

Contraste con otra fuente: Este artículo contrasta productivamente con Damen et al. (2016): mientras D'Agostino presenta el desarrollo y validación exitosa de un modelo específico (Framingham), Damen et al. muestran en una revisión de 363 modelos que ese nivel de validación externa es la excepción y no la regla en el campo. Esto resuelve una pregunta que D'Agostino deja implícita: ¿qué tan representativo es el caso Framingham del estado general de la predicción cardiovascular? La respuesta de Damen es que la mayoría de modelos publicados carecen de validación externa adecuada, lo que refuerza la necesidad de ser cautelosos al interpretar los resultados de nuestro propio modelo, especialmente considerando que `cardio_train.csv` no especifica origen geográfico y no permite una validación externa rigurosa.

Evaluación de aplicabilidad (4/5): La metodología del modelo de Cox y la regresión logística son directamente aplicables a nuestros datos, ya que compartimos las mismas variables de entrada (presión arterial, colesterol, edad, tabaquismo) y la misma variable respuesta binaria. Se descuenta un punto porque nuestro *dataset* no incluye colesterol HDL por separado ni información sobre tratamiento antihipertensivo, variables que el modelo Framingham considera relevantes para la estimación del riesgo.

Pregunta que le haría al autor: ¿Cómo afecta el rendimiento del modelo cuando la edad está registrada en días en lugar de años y no se dispone de información sobre el origen geográfico de los pacientes, como ocurre en *datasets* clínicos de acceso público como `cardio_train.csv`?

Resumen argumentativo: El problema que D'Agostino y colaboradores intentan resolver es cómo combinar múltiples factores de riesgo clínico en una función matemática única que permita estimar de forma precisa y generalizable la probabilidad individual de desarrollar enfermedad cardiovascular. La solución propuesta —las Framingham Risk Functions basadas

en el modelo de Cox— funciona bien para nuestro contexto porque las variables de entrada del modelo original (presión arterial, colesterol, tabaquismo, edad, glucosa) coinciden casi exactamente con las disponibles en `cardio_train.csv`. Sin embargo, presenta una limitación relevante: fue desarrollada en una población geográficamente homogénea, mientras que nuestro *dataset* no especifica el origen de sus pacientes, lo que introduce incertidumbre sobre la transportabilidad directa de los coeficientes. A pesar de esto, el elemento que usaremos de este documento es el marco de evaluación de modelos que propone: adoptaremos el C-estadístico como medida de discriminación y la comparación entre probabilidades predichas y tasas observadas como criterio de calibración para juzgar la calidad de los modelos de clasificación que desarrollaremos sobre la variable respuesta binaria de nuestro *dataset*.

1.4 Ficha de Literatura 2

1.4.1 Nivel descriptivo

Título: Prediction models for cardiovascular disease risk in the general population: systematic review

Autor(es): Damen, J. A. A. G.; Hooft, L.; Schuit, E.; Debray, T. P. A.; Collins, G. S.; Tzoulaki, I.; Lassale, C. M.; Siontis, G. C. M.; Chiocchia, V.; Roberts, C.; Schlüssel, M. M.; Gerry, S.; Black, J. A.; Heus, P.; Van der Schouw, Y. T.; Peelen, L. M.; Moons, K. G. M.

Año: 2016

Nombre del tema: Panorama general del estado del arte en modelos de predicción de riesgo cardiovascular en población general, con énfasis en sus limitaciones metodológicas y la falta de validación externa.

Clasificación: *Temática* — se eligió esta etiqueta porque el documento no desarrolla ni aplica un método estadístico concreto (metodológica), no propone un marco conceptual nuevo (teórica) ni organiza el conocimiento por orden temporal (cronológica); su propósito es mapear el estado del campo mediante una revisión sistemática de 363 modelos existentes, lo cual es una contribución temática sobre el problema de la predicción cardiovascular en su conjunto.

Resumen en una oración: Revisión sistemática de 363 modelos de predicción cardiovascular revela deficiencias generalizadas de validación externa.

Argumento central: Existe un exceso de modelos predictivos para riesgo cardiovascular en la población general, pero la utilidad de la mayoría permanece incierta debido a deficiencias metodológicas recurrentes: tamaños de muestra inadecuados, presentación incompleta de los modelos, ausencia de validación externa y falta de estudios de impacto clínico. Los predictores más frecuentes en los modelos revisados son edad, sexo, tabaquismo, presión arterial sistólica,

colesterol total y diabetes, lo cual confirma la relevancia de las variables disponibles en *datasets* clínicos observacionales.

Problemas con el argumento o el tema: Los autores reconocen que la revisión cubre literatura hasta junio de 2013, por lo que no incluye desarrollos metodológicos más recientes como modelos de machine learning o técnicas de aprendizaje profundo. Además, la heterogeneidad de los estudios revisados dificulta comparaciones directas entre modelos, ya que difieren en poblaciones objetivo, definiciones de desenlace y horizontes temporales de predicción.

1.4.2 Nivel analítico

Conexión con mi proyecto: Este artículo contextualiza directamente nuestro proyecto al mostrar que las variables más frecuentes en modelos de predicción cardiovascular validados —edad, presión arterial sistólica, colesterol y tabaquismo— son precisamente las que contiene `cardio_train.csv`. Además, la principal conclusión del artículo (que la mayoría de modelos carecen de validación externa adecuada) nos alerta sobre la necesidad de no limitarnos a reportar métricas de exactitud, sino de incluir también análisis de calibración y, en la medida de lo posible, discutir las limitaciones de generalización de nuestros modelos.

Lo que NO dice el autor: La revisión no aborda *datasets* de acceso público como `cardio_train.csv` ni discute si modelos entrenados sobre datos sin contexto geográfico definido pueden considerarse válidos para alguna población específica. Tampoco evalúa modelos de machine learning, que son los que planeamos comparar en nuestro proyecto, lo que representa una brecha que trabajos más recientes como Ogunpola et al. (2024) comienzan a llenar.

Contraste con otra fuente: Este artículo complementa a D'Agostino et al. (2013) desde una perspectiva crítica: mientras Framingham presenta un modelo específico con buena validación externa como caso de éxito, Damen et al. muestran que ese caso es la excepción y no la regla — la mayoría de los 363 modelos revisados no alcanza ese estándar de validación. Esto resuelve una pregunta que D'Agostino deja abierta: ¿qué tan generalizable es el enfoque Framingham al campo en general? La respuesta de Damen es que muy pocos modelos logran esa generalización, lo que refuerza la importancia de ser cautelosos al interpretar los resultados de nuestro propio modelo entrenado sobre un *dataset* sin origen geográfico definido.

Evaluación de aplicabilidad (3/5): La revisión no proporciona una metodología directamente aplicable a nuestros datos, ya que es un estudio de estudios y no un modelo predictivo en sí mismo. Sin embargo, su valor para nuestro proyecto es normativo: establece los criterios mínimos que un modelo de predicción cardiovascular debería cumplir (reporte completo, validación interna y externa, análisis de calibración), los cuales usaremos como lista de verificación para evaluar y comunicar las limitaciones de nuestros propios modelos.

Pregunta que le haría al autor: Dado que la mayoría de los modelos revisados fueron desarrollados en Europa y Norteamérica, ¿cómo afecta la ausencia de información geográfica en *datasets* como `cardio_train.csv` a la posibilidad de clasificar o comparar un modelo derivado de ellos con los estándares de validación que propone esta revisión?

Resumen argumentativo: El problema que Damen et al. intentan resolver es la falta de visibilidad sobre el estado real del campo de predicción de riesgo cardiovascular: ¿cuántos modelos existen, qué variables usan y qué tan bien están validados? Su respuesta es que el campo está fragmentado y que la mayoría de los modelos publicados tienen deficiencias metodológicas que impiden su uso clínico confiable. Esta conclusión funciona bien para nuestro contexto porque nos advierte que entrenar un modelo con alta exactitud sobre `cardio_train.csv` no es suficiente: debemos reportar sus limitaciones de validación con honestidad. Sin embargo, el artículo no resuelve cómo proceder cuando los datos disponibles no permiten una validación externa rigurosa, que es precisamente nuestra situación. El elemento que incorporaremos de este documento es su lista de predictores más frecuentes en modelos validados (edad, presión arterial, colesterol, tabaquismo, diabetes), que usaremos para justificar la relevancia de las variables de nuestro *dataset*, y su marco crítico de evaluación, que adoptaremos para discutir honestamente las limitaciones de generalización de nuestros resultados.

1.5 Ficha de Literatura 3

1.5.1 Nivel descriptivo

Título: Why clinicians are natural Bayesians

Autor(es): Christopher J. Gill, Lora Sabin y Christopher H. Schmid.

Año: 2005

Nombre del tema: La aplicación intuitiva y formal del teorema de Bayes en el razonamiento del diagnóstico clínico.

Clasificación: *Estado de arte* — se eligió pues es una documentación muy temprana del uso del factor de Bayes en la cardiología. Provee una idea esencial que, complementada con otros artículos, define el enfoque bayesiano como útil para la investigación.

Resumen en una oración: El artículo demuestra cómo los médicos utilizan intuitivamente el pensamiento probabilístico para diagnosticar pacientes.

Argumento central: El proceso diagnóstico no es una deducción binaria, sino una actualización constante de probabilidades donde la experiencia previa (probabilidad pre-test) se combina con nueva evidencia para generar una conclusión clínica.

Problemas con el argumento o el tema: Los autores identifican que, aunque los médicos son "bayesianos naturales", a menudo tienen dificultades para realizar cálculos matemáticos

precisos bajo presión y pueden verse afectados por sesgos cognitivos al estimar probabilidades subjetivas.

1.5.2 Nivel analítico

Conexión con mi proyecto: En particular, este artículo es útil para el objetivo de la investigación. Primero, porque la importancia de conocer la influencia de características en el riesgo cardiovascular depende no de un si o no, sino un espectro de probabilidad; un tema que se observa a lo largo de esta obra, especialmente al principio. Otra relación al tema llega a la interpretación de patrones con los datos, pues el artículo introduce el concepto de verosimilitud (*Likelihood ratio*) para explicar que un patrón (o característica) es útil solo si es significativamente más probable en personas enfermas que en personas sanas. Además, explica que ciertos patrones como positivos falsos que pueden estar presentes en personas sanas, y el análisis bayesiano ayuda a distinguir cuándo un patrón es un "ruido" estadístico o una señal real de patología cardíaca. El tema de los falsos positivos y negativos se observa en otros artículos además de éste.

Lo que NO dice el autor: No responde cómo influye y cuánto influyen las carácterísticas, pues es una limitación del artículo es que no es cuantitativo, sino que explica más sobre por qué se usa el factor de Bayes. Por ejemplo, si no se sabe a priori cómo influye el tabaquismo en el corazón, no es posible asignar ese valor numérico que el artículo exige para actualizar nuestra sospecha clínica.

Contraste con otra fuente: Se contrasta con D'Agostino et al. pues, similarmente al último, D'Agostino usa metodología del modelo de Cox. Muy rígido comparado a la de Gill et al. que usa el factor de Bayes que es más flexible porque permite al médico ajustar la probabilidad incluso con información incompleta o "ruidosa", combinando su experiencia con los datos del paciente de forma fluida. Gill et al. demuestra el ámbito más realista de cómo se usa la probabilidad en tiempo real mientras que D'Angelo et al demuestra un lado más teórico y predictivo.

Evaluación de aplicabilidad (4.5/5): Es muy seguro que el enfoque bayesiano va a ser el enfoque principal de la investigación, pues no sólamente se referencia Gill et al. sobre este tema sino que varias otras obras. No obstante, la simplicidad de éste aporta al desarrollo de la metodología.

Pregunta que le haría al autor: Después de leer el artículo, es fácil saber por qué son bayesianos los clínicos, pero una pregunta que se puede establecer es: ¿Cuáles son las razones de por qué los clínicos NO son frecuentistas?. Parece un poco obvia a plena vista, pues se puede confundir con "¿Por qué los clínicos NO son frecuentistas?". Sin embargo, esta pregunta brinda otras ideas como la precisión de cáclulos bayesianos contra frecuentistas, entre otros.

Resumen argumentativo: El problema que intenta resolver Gill et al. es la brecha entre la teoría estadística formal y la práctica clínica real. Los autores argumentan que los médicos ven a ésta como un conjunto de reglas en lugar de usarlos en todos los diagnósticos en sí. En conjunto, la solución no funciona completamente pues una brecha grande de ésta es la falta de datos específicos y qué características afectan el riesgo de un individuo. Por eso es que se debe complementar con otros artículos para llenar algunos de estos huecos en el conocimiento para el proyecto. Sin embargo, si provee una ventana a lo que se ha escrito de la estadística y los problemas médicos, además de metodología y conceptos útiles como el uso de la verosimilitud y factor de bayes para diagnósticos.

1.6 UVE de Gowin

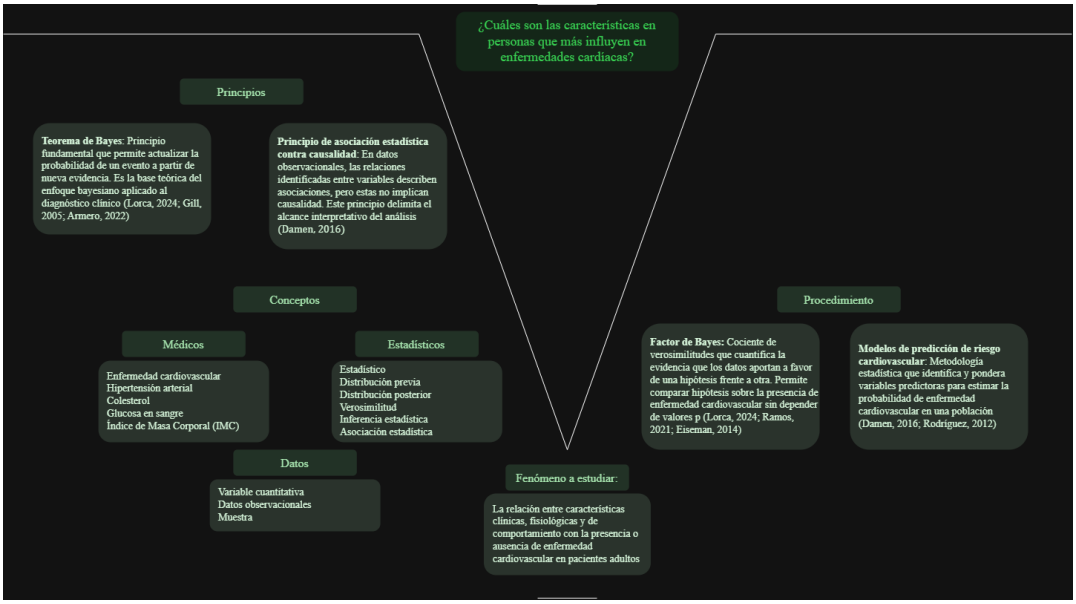

Figura 2: UVE de Gowin: relación entre el dominio conceptual y metodológico del estudio de enfermedades cardiovasculares.

1.7 Parte de escritura

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel mundial, y su estudio estadístico tiene especial relevancia para disciplinas como en Ciencias Actuariales, donde la estimación precisa del riesgo de vida de un asegurado depende directamente de identificar qué características clínicas y de comportamiento se asocian con

mayor probabilidad de padecerlas. En este contexto, la pregunta que guía el presente proyecto es: **¿cuáles son las características en personas que más influyen en enfermedades cardíacas?**

Para responder la pregunta, se utiliza el **Cardiovascular Disease *dataset*** (Ulianova, 2019), disponible públicamente en Kaggle, compuesto por aproximadamente 70,000 registros de pacientes adultos con variables demográficas (edad, género), fisiológicas (altura, peso, presión arterial sistólica y diastólica), bioquímicas (colesterol y glucosa) y de comportamiento (tabaquismo, consumo de alcohol y actividad física). La variable respuesta es binaria: presencia o ausencia de enfermedad cardiovascular. Al ser datos observacionales, las relaciones que se identifiquen deben interpretarse como asociaciones estadísticas y no como relaciones causales. Una limitación relevante es la ausencia de variables como antecedentes familiares y etnia, reconocidas por la World Heart Federation (2023) como factores de riesgo cardiovascular, lo que acota el poder explicativo del modelo.

El análisis se abordará desde un **enfoque bayesiano**, decisión que encuentra respaldo en la literatura revisada. Gill et al. (2005) argumenta que la inferencia bayesiana es especialmente adecuada en contextos clínicos porque no produce una respuesta dicotómica de sí o no, sino una probabilidad condicional que incorpora el contexto en que se realiza la prueba, lo cual resulta más informativo para la toma de decisiones médicas y actuariales. Esta postura es consistente con lo planteado por Lorca & Águila (2024) y Armero et al. (2022), quienes demuestran que el enfoque bayesiano permite incorporar conocimiento previo sobre la prevalencia de enfermedades y actualizar las estimaciones de riesgo a medida que se observan nuevos datos, una ventaja concreta frente al enfoque frecuentista cuando se trabaja con poblaciones heterogéneas o muestras de tamaño variable.

Dentro de este marco, una herramienta metodológica central para el proyecto es el **Factor de Bayes**, ampliamente utilizado en cardiología clínica (Eiseman et al., 2014; Ramos-Vera, 2021). Este estadístico permite cuantificar cuánta evidencia aportan los datos a favor de una hipótesis sobre otra, lo que resulta especialmente útil para comparar el peso relativo de distintos factores de riesgo en la predicción de enfermedad cardiovascular. Kaufmann et al. (2019) extiende esta lógica mediante redes bayesianas, modelando las dependencias condicionales entre múltiples variables clínicas simultáneamente, lo que ofrece una perspectiva metodológica más completa que los modelos univariados.

La revisión bibliográfica también revela que la naturaleza multifactorial de las enfermedades cardiovasculares hace indispensable el uso de modelos que consideren varias variables de forma conjunta. D'Agostino et al. (2013) demuestra que funciones de riesgo multivariables, como las derivadas del Estudio Framingham, combinando edad, presión arterial sistólica, colesterol, tabaquismo y glucosa, alcanzan una capacidad discriminativa sólida (C-estadístico entre 0.79 y 0.83). Esta evidencia valida directamente la pertinencia de las variables contenidas en el *dataset* utilizado. Por su parte, Damen et al. (2016), en una revisión sistemática de más de 100 modelos predictivos de riesgo cardiovascular, señala que las variables con mayor presencia transversal en los modelos son edad, tabaquismo, presión arterial y colesterol, todas disponibles en los datos del proyecto. Rodríguez-Escudero et al. (2012) complementa esta perspectiva al

destacar que la edad y el sexo operan como modificadores de riesgo fundamentales, dado que la supervivencia en función de la edad sigue una distribución exponencial que condiciona el riesgo cardiovascular acumulado.

En resumen, existe evidencia científica consolidada de que las enfermedades cardiovasculares responden a un conjunto identificable de características medibles, y que la estadística bayesiana ofrece las herramientas más adecuadas para estimar el peso de esas características en una población como la del *dataset* disponible. El problema que este proyecto busca abordar es la identificación rigurosa de qué variables tienen mayor influencia predictiva cuando se combinan factores demográficos, fisiológicos, bioquímicos y de comportamiento en una muestra de esta escala, aplicando un enfoque inferencial bayesiano con distribuciones previas conjugadas.

1.8 Arco narrativo del proyecto

"El problema que nadie ha resuelto completamente aún es identificar con claridad cuáles características individuales tienen mayor influencia en las enfermedades cardíacas a partir de los datos"

1.9 Diario de aprendizaje

Como equipo, hemos aprendido que el análisis de datos no comienza con la aplicación de métodos, sino con la correcta formulación de una pregunta de investigación alineada con los datos disponibles y de esta forma tener claro cual camino seguir. Al inicio no teníamos claro cómo delimitar una idea en un problema investigable, pero ahora entendemos la importancia de estructurar el enfoque del proyecto desde etapas tempranas, para asi que el flujo de trabajo vaya en la mejor forma. También comprendimos que los datos observacionales no permiten establecer relaciones causales, sino asociaciones, lo que influye directamente en la interpretación de los resultados. Además, identificamos que las limitaciones del *dataset* condicionan el alcance del análisis. Finalmente, aprendimos que la toma de decisiones es un proceso clave que impacta el desarrollo del proyecto, ya que debido a esto se define cómo se analiza la información y qué conclusiones se pueden obtener.

1.10 Rastro de decisiones

1.10.1 Decisión 1: Uso del *dataset*

- Opciones consideradas:
  - Buscar múltiples *datasets*
  - Utilizar un único *dataset* de Kaggle
- Opción elegida:

  - *dataset* de Kaggle sobre enfermedades cardíacas

- Opciones descartadas:
  - Integración de múltiples fuentes de datos

- Justificación:
  - El *dataset* de Kaggle es accesible, estructurado y contiene variables relevantes para el análisis, lo que permite avanzar de forma eficiente sin necesidad de procesos complejos de integración de datos, además de ser proveniente de una fuente confiable y de uso sencillo y un tema adecuado.

1.10.2 Decisión 2: Enfoque del proyecto

- Opciones consideradas:
  - Construir un modelo predictivo de enfermedades cardíacas
  - Analizar la relación entre variables y la enfermedad

- Opción elegida:
  - Análisis de la relación entre características y enfermedades cardíacas

- Opciones descartadas:
  - Modelo predictivo completo

- Justificación:
  - El desarrollo de modelos predictivos requiere herramientas y conocimientos más avanzados (machine learning) que no son parte del curso. Por ello, y recomendacion del profesor, se decidió enfocarse en un análisis exploratorio y descriptivo que permita identificar relaciones relevantes entre variables.

1.10.3 Decisión 3: Selección de la pregunta de investigación

- Opciones consideradas:
  - ¿Qué importancia tiene conocer estas características?
  - ¿Cómo influyen estas características?
  - ¿Cuáles características influyen más?
  - ¿Qué patrones presentan estas características?

- Opción elegida:
  - ¿Cuáles son las características en personas que más influyen en enfermedades cardíacas?

- Opciones descartadas:
  - Preguntas demasiado generales o conceptuales
- Justificación:
  - La pregunta seleccionada permite un análisis directo con los datos disponibles, facilitando la identificación de variables relevantes mediante métodos estadísticos, además de ser la que nos sonó mas acertada.

1.11 Registro de uso de IA

1.11.1 Consulta: Redacción audiencia y posicionamiento

Prompt resumido: Revisa la redacción de audiencia y posicionamiento del equipo.

Respuesta de la IA resumido: Dio propuesta de párrafo de audiencia enfocado en actuarios de vida y salud. Recomendó para posicionamiento: categorías a reflexionar, como relevancia profesional, interés genuino y habilidades del equipo.

Evaluación: Si se redactó de mejor forma la propuesta del párrafo de audiencia y posicionamiento. Además, fue buena la idea de agregar trabajos o pasantías de los integrantes del grupo.

Modificaciones: El proyecto inicialmente estaba dirigida oúnicamente a actuarios del área de salud, ahora va dirigido también a los de vida. Además, se corrigieron errores ortográficos y se refinó la redacción sustituyendo términos generales por vocabulario técnico más preciso.

Aprendizaje: Lenguaje más técnico y se amplió el alcance de la audiencia inicialmente concebida, reconociendo que los hallazgos pueden ser relevantes para perfiles más diversos dentro del sector asegurador.

1.11.2 Consulta: Revisión de preguntas de investigación y tensiones

Herramienta: Claude

Prompt resumido: Revisa las 4 preguntas formuladas y la sección de tensiones.

Respuesta de la IA resumida: Dijo que la pregunta 1 era la más débil y propuso reformulación más sólida. En tensiones señaló que las mismas estaban mezcladas en un solo párrafo, que la expresión “muy dispersos” era vaga, y que faltaba conectar la tercera tensión con sus consecuencias analíticas. Ofreció versión reescrita.

Evaluación: Solo cambió una pregunta, hubiera sido mejor que mejorara la redacción de todas la preguntas.

Modificaciones: Se reformula la pregunta 1 completamente, pasa de "¿qué es?" a "¿qué importancia tiene?"

Aprendizaje: Hablar de qué son las características que influyen en las enfermedades del corazón no aporta mucho a la investigación, pues se responde con una definición y listo. Hablar de la importancia en cambio puede derivar en más conceptos y definiciones.

1.11.3 Consulta: Preguntas de lógica, ética y emocional

Herramienta: ChatGPT Plus

Prompt: "Ayúdame a elaborar argumentos y contraargumentos para preguntas de lógica, ética y emoción, de manera que pueda identificar qué tipo de respuesta corresponde a cada elemento y luego adaptarlas a un tono más natural y comprensible."

Respuesta de la IA: La herramienta generó propuestas de argumentos y contraargumentos para cada una de las dimensiones solicitadas: lógica, ética y emocional. Estas respuestas sirvieron como guía inicial para reconocer la estructura esperada en cada tipo de argumentación y diferenciar el enfoque adecuado según el elemento analizado, dado a que inicialmente no se comprendia la naturaleza que debian tener las respuestas a dichas preguntas.

Evaluación: Fue útil porque permitió contar con una base inicial de ideas y ejemplos sobre cómo desarrollar argumentos y contraargumentos según cada perspectiva. Sin embargo, algunas respuestas eran demasiado generales o sonaban poco naturales, por lo que no podían incorporarse directamente al trabajo sin una revisión previa, por lo que seguido de una comprensión de lo que representaba cada parte de las preguntas, se continuó con su elaboración completa.

Modificaciones: Las respuestas generadas por la IA fueron reorganizadas, reformuladas y adaptadas con un lenguaje más natural, para que reflejaran mejor la forma en que el equipo comprendía y expresaba las ideas. Además, se ajustó la redacción para que los argumentos estuvieran más alineados con el contexto del trabajo.

Aprendizaje: Se aprendió a distinguir con mayor claridad las características de una argumentación lógica, ética y emocional, así como la forma en que los contraargumentos deben construirse según cada caso. También se comprendió la importancia de no copiar literalmente la respuesta de la IA, sino usarla como apoyo para desarrollar una redacción propia y mejor entendida.

1.11.4 Consulta: Revisión de la sección 1.1.6

Herramienta: Claude (Anthropic)

Prompt: "según estas indicaciones y esta descripción del dataset, dime si la sección 1.1.6 está cubierta de manera correcta"

Respuesta de la IA: Claude revisó la sección 1.1.6 que ya había sido redactada por el equipo, e identificó qué campos cumplían con lo solicitado y cuáles necesitaban refuerzo. Señaló que el contexto temporal y espacial no discutía las implicaciones concretas de esa limitación para la pregunta de investigación, y que la conexión entre cada variable y la pregunta de investigación no estaba explícita.

Evaluación: Fue útil para obtener una revisión externa del texto ya redactado y detectar vacíos que desde adentro eran difíciles de ver. Sin embargo, algunas sugerencias eran demasiado generales y no consideraban el tono ni el enfoque que el equipo ya había establecido, por lo que no podían incorporarse directamente.

Modificaciones: La retroalimentación de Claude se usó como lista de verificación. Las secciones señaladas como incompletas fueron reescritas por el equipo, usando las observaciones como guía pero manteniendo la redacción y el criterio propio. Claude generó una versión de referencia que sirvió de borrador, pero el texto final fue ajustado en tono y contenido.

Aprendizaje: Se comprendió que describir variables no es lo mismo que argumentar su relevancia para la investigación. Cada variable debe estar justificada en función de la pregunta de investigación, no solo listada.

1.11.5 Consulta: Apoyo en el formato de la ficha de D'Agostino et al. (2013)

Herramienta: Claude (Anthropic)

Prompt: "ayúdame a hacer la ficha de literatura de esta referencia, ya tengo una estructura base pero necesito completar los campos del nivel descriptivo según las indicaciones del profesor"

Respuesta de la IA: Claude complementó la ficha que el equipo había comenzado sobre D'Agostino et al. (2013), apoyando en la redacción de los campos del nivel descriptivo que estaban incompletos, como el resumen en una oración, el argumento central y los problemas con el argumento. También sugirió ajustes al campo de clasificación para que cumpliera con el formato exacto solicitado por el profesor.

Evaluación: Fue útil para estructurar los campos descriptivos de forma ordenada y verificar que el formato correspondía exactamente a lo pedido. Sin embargo, el resumen en una oración generado excedía el límite de palabras establecido por el profesor y el argumento central usaba un lenguaje más técnico del apropiado para el nivel del curso.

Modificaciones: El resumen en una oración fue reescrito por el equipo para ajustarse al límite de 10 a 15 palabras. El argumento central fue simplificado en su redacción. Los campos del nivel analítico fueron redactados completamente por el equipo, ya que requieren conectar el artículo con el proyecto propio y eso exige un juicio que solo el equipo puede ejercer.

Aprendizaje: Se aprendió que la parte más importante de una ficha de literatura es el nivel analítico, ya que requiere conectar el documento leído con el proyecto propio. Esa conexión no puede construirse sin haber leído el artículo y tener claro el contexto del trabajo.

1.11.6 Consulta: Apoyo en el formato de la ficha de Damen et al. (2016)

Herramienta: Claude (Anthropic)

Prompt: "completa los campos descriptivos que me faltan en la ficha de Damen et al., que ya está en mi archivo de bibliografía"

Respuesta de la IA: Claude completó los campos descriptivos faltantes de la ficha de Damen et al. (2016) que el equipo tenía iniciada, desarrollando principalmente el resumen en una oración, el argumento central y los problemas con el argumento, a partir de la información extraída del artículo.

Evaluación: Fue útil para agilizar la redacción de los campos descriptivos y asegurarse de que la información extraída del artículo era correcta. El borrador capturó bien las ideas principales, aunque el lenguaje era más técnico de lo necesario y algunos detalles no eran precisos respecto al alcance real del estudio.

Modificaciones: Los campos generados fueron simplificados en su redacción para reflejar el nivel de comprensión del equipo. Los campos del nivel analítico, incluyendo la conexión con el proyecto, el contraste entre fuentes y el resumen argumentativo, fueron redactados completamente por el equipo a partir de la lectura propia del artículo y del razonamiento sobre su utilidad para el proyecto.

Aprendizaje: Se comprendió el valor de las revisiones sistemáticas como fuente bibliográfica: no aportan un método concreto sino un panorama crítico del campo, lo cual es igual de valioso para contextualizar las decisiones metodológicas propias y reconocer honestamente las limitaciones del trabajo.

1.11.7 Consulta: Revisión Bibliográfica

Para la sección de revisión bibliográfica, se uso la inteligencia artificial de Google Gemini sólamente para ayudar a buscar referencias. El nivel de las referencias resultó siendo un rango que variaba de adecuado a muy ambicioso para el proyecto. La ventaja de esta IA es que al ser de Google, tiene una opción llamada *DeepResearch*, donde procesa la solicitud por un tiempo prolongado antes de entregar un resultado donde lista una gran cantidad de sitios donde encontró la información. Lo interesante no fue mucho el resultado, pues la interpretación se hizo sin mucha ayuda de la IA; aunque se usó para clasificar ciertos artículos para facilitar el encadenamiento de ideas, aunque algunos referenciados no fueron usados al final. Sino, los sitios que brindó muchos fueron escogidos directamente de éste. A continuación se muestra los

prompts usados y el archivo en *Google Docs* que brindó. Es importante denotar que no todas las fuentes se sacaron de éste, sino que fue fruto de investigación propia.

Prompt 1: Adquisición de sitios Resultado: https://docs.google.com/document/d/14ii_ogSwLz_tq7yO52Qays3H

Prompt 2.1: Encadenamiento de ideas Resultado: Parte 1 Parte 2 Parte 3 Parte 4

1.11.8 Consulta: Consulta sobre UVE de Gowin

Herramienta: Claude

Prompt resumido: Qué herramientas puedo usar para construir la UVE, qué va en cada parte, qué conceptos debería poner sobre enfermedades cardiovasculares.

Respuesta de la IA resumida: Recomendó draw.io sobre Canva; explicó la estructura V y la diferencia entre objeto de estudio e instrumento; dio una lista de conceptos clínicos y estadísticos; recomendó usar principios y prodecimientos del marco teórico y dio formatos de cita en APA para draw.io.

Evaluación: Draw.io fue una elección acertada, incluso recomendó que paletas de colores usar en la V, por lo que fue de mucha ayuda.

Modificaciones: No cambió nada, solo recomendó herramientas a utilizar.

Aprendizaje: Se tiene más claridad sobre la composición de la UVE, además de cómo acomodar la información del proyecto dentro de la UVE.

1.12 Marco teórico

Para esta investigación se van a utilizar conceptos fundamentales de la estadística y probabilidad que influyen el proceso en los factores de riesgo en ciertas demografías. A continuación se va a elaborar no solamente los enfoques probabilísticos y estadísticos para la investigación sino también otros conceptos no completamente relacionados a esos. El presente reporte articula un marco teórico exhaustivo que responde a la necesidad de identificar patrones, jerarquizar influencias y modelar la probabilidad de eventos adversos, integrando la estadística clásica con las fronteras del aprendizaje automático y la inferencia causal.

En primer lugar, se deben introducir ciertas definiciones básicas de estadística antes de profundizar los enfoques que se van abordar.

De acuerdo a DeGroot & Schrevish (2012) , Suponga que la cantidad observable de variables aleatorias de interés son $X_1, \cdots, X_n$. Sea r una función arbitraria con valores reales. Entonces la variable aleatoria $T = r(X_1, \cdots, X_n)$ es un **estadístico**. Tres ejemplos de estadísticos son la media aritmética $\bar{X}n$, el máximo Yn de los valores $X_1, \cdots, X_n$ y la función $r(X_1, \cdots, X_n)$, que tiene el valor constante de 3 para todos los valores de $X_1, \cdots, X_n$. (p. 382) Un estadístico entonces es una función que conjuga una cantidad definida de variables aleatorias y devuelve

un número real. Para efectos de esta investigación, es un concepto integral para las siguientes definiciones ya que se utiliza para inferir propiedades de una población.

De la misma obra, se van a definir dos conceptos adicionales a éstos. La **distribución previa** por ejemplo, Suponga que uno tiene un modelo estadístico con parámetro θ. Si uno trata θ como aleatorio entonces la distribución que le da a θ antes de observar las otras variables aleatorias de interés. Eso se llama la distribución previa. Si el espacio donde está θ es contable, entonces la distribución previa es discreta y se refiere como *p.f. previa*, si θ es continua, se refiere como *p.d.f previa* pues sería continua la distribución previa. Se va a denotar $\xi(\theta)$ como ambas p.f y p.d.f en función de solo theta. (p. 385) La distribución previa es una función de una variable θ, donde theta es el parámetro de la distribución de una variable aleatoria de interés, que a priori se sabe su distribución. Nota: de ahora en adelante, se va a referir a $\xi(\theta)$ como $\pi(\theta)$.

Después sigue la **distribución posterior** que se demuestra como La distribución condicional de θ dado $x_1, ..., x_n$. La p.f. o p.d.f. de θ dado $X = x_1,X_2 = x_2..., X_n = x_n $ se llama la p.f. posterior o p.d.f. posterior y se denota $\xi(\theta|x1, .., xn)$. (...) Si se supone que este parámetro θ es desconocido y la p.f o p.d.f previa de theta es $\xi(\theta)$. Entonces la p.d.f o p.f. posterior de θ es

$$\xi(\theta \mid \mathbf{x}) = \frac{f(x_1 \mid \theta) \cdots f(x_n \mid \theta)\xi(\theta)}{g_n(\theta)}; \quad \theta \in \Omega$$
$$\text{donde } g_n = \int \cdots \int_{\Omega_{X_1}, \cdots, \Omega_{X_n}} f(x_1 \mid \theta) \cdots f(x_n \mid \theta)\xi(\theta)$$

(p. 387-388) Luego en la página 388, el denominador de la posterior se define como la **p.f. o p.d.f junta marginal de $\mathbf{X_1}, \cdots, \mathbf{X_n}$**, y se denota por $g_n(x)$, El numerador de la posterior se define como la **verosimilitud** y se denota por $\mathcal{L}(\theta|\mathbf{x})$. Similarmente a la previa, la distribución posterior ($\xi(\theta|\mathbf{x})$)se va a denotar de ahora en adelante como $\pi(\theta|\mathbf{x})$

Ya con varios conceptos fundamentales definidos, hay dos enfoques estadísticos que se pueden usar para la investigación. Esos son el **Bayesiano** o el **frecuentista o clásico**. Se van a definir ambos - sin embargo es indudable que se va a usar el enfoque bayesiano por razones que se van a especificar a lo largo de esta sección.

El **enfoque clásico o frecuentista** consiste en La idea de que, si un experimento fuese a ser replicado una gran cantidad de veces, se puede establecer una distribución de muestra de un estadístico específico, como $\bar{X}_d$. Se reconoce que el valor que se obtiene cada vez será diferente cuando se repite el experimento porque los participantes totales siempre cambian (...) Dado la distribución de $\bar{X}_d$, se puede estimar el exento de la variabilidad, el error o la desviación del estadístico μ_d. Pek & Van Zandt (2019) Asimismo, el frecuentista establece que al tener datos grandes, los estadísticos cambian cada vez que se suman datos nuevos, por lo que se usan datos históricos para definir estos nuevos estadísticos. Este enfoque tiene sus ventajas al tener datos más grandes, más repetibles y con mejores datos históricos.

El **enfoque bayesiano** es completamente diferente al clásico pues En lugar de la distribución de X_d, el enfoque bayesiano usa la distribución posterior del parámetro de éstos. Como se ha descrito, la posterior depende de la selección de la distribución previa del parámetro y la verosimilitud. Por ejemplo, si se toma datos que siguen una distribución normal con media μ y desviación estándar 0; y si además se escoge una distribución previa para μ de media 1 y desviación 0, tendrá una posterior con media .41 y desviación $\sqrt{2}$ (Bolstad, 2010). Usando esta posterior, se pueden calcular las probabilidades de que μ tome valores dentro de un intervalo de interés.

La diferencia mayor entre ambos es claramente el uso de la posterior. Por lo que el enfoque bayesiano y clásico ambos crean intervalos en los que puede "vivir" el parámetro, la manera en que se construye es muy diferente. De una manera resumida, el enfoque bayesiano usa la distribución previa de los parámetros para crear un **intervalo creíble de Bayes** donde se estima que 95% de estos parámetros podrían estar ubicados ahí, mas el enfoque clásico usa estadísticos "viejos" y los varía a través de un **intervalo de confianza**, donde se estima que 95% de los valores posibles del parámetro pueden llegar a estar ahí.

1.13 Log de contribuciones

Integrante	Sección / Tarea realizada
César Salazar	Definición de la idea, Conceptualización, Identificación de tensiones, Cuatro preguntas y párrafo de descarte, Audiencia del proyecto, Posicionamiento del equipo, UVE de Gowin
Gerardo Montero	Argumentación preguntas 1, 2 y 3, Rastro de decisiones, Arco narrativo, Diario de aprendizaje
Óscar Espinoza	Argumentación pregunta 4, Descripción del *dataset*, 2 fichas de literatura
Gabriel Robles	Búsqueda bibliográfica, Organización en `.bib`, Identificación de teorías/principios y metodologías, Marco teórico, 1 ficha de literatura

1.14 Referencias

Armero, C., Rodríguez Y, P., & Torre Hernández, J. M. D. L. (2022). Una pequñea mirada a la estadística bayesiana en el análisis de datos cardiológicos. *REC: interventional cardiology*, 8378. https://doi.org/10.24875/RECIC.M22000284

D'Agostino, R. B., Pencina, M. J., Massaro, J. M., & Coady, S. (2013). Cardiovascular Disease Risk Assessment: Insights from Framingham. *Global Heart*, *8*(1), 11-23. https://doi.org/10.1016/j.gheart.2013.01.001

Damen, J. A. A. G., Hooft, L., Schuit, E., Debray, T. P. A., Collins, G. S., Tzoulaki, I., Lassale, C. M., Siontis, G. C. M., Chiocchia, V., Roberts, C., Schlüssel, M. M., Gerry, S., Black, J. A., Heus, P., Van Der Schouw, Y. T., Peelen, L. M., & Moons, K. G. M. (2016). Prediction models for cardiovascular disease risk in the general population: systematic review. *BMJ*, i2416. https://doi.org/10.1136/bmj.i2416

DeGroot, M., & Schrevish, M. (2012). *Probability & Statistics* (4.ª ed.). Pearson. https://educationexclusive.com/upload/pdf/Probability%20and%20Statistics%20by%20Morris%20H.%20DeGroot%20and%20Mark%20J.%20Schervish.pdf

Eiseman, N. A., Bianchi, M. T., & Westover, M. B. (2014). The Information Theoretic Perspective on Medical Diagnostic Inference. *Hospital Practice*, *42*(2), 125-138. https://doi.org/10.3810/hp.2014.04.1110

Gill, C. J., Sabin, L., & Schmid, C. H. (2005). Why clinicians are natural bayesians. *BMJ*, *330*(7499), 1080-1083. https://doi.org/10.1136/bmj.330.7499.1080

Kaufmann, T., Castela Forte, J., Hiemstra, B., Wiering, M. A., Grzegorczyk, M., Epema, A. H., Van Der Horst, I. C. C., & SICS Study Group. (2019). A Bayesian Network Analysis of the Diagnostic Process and its Accuracy to Determine How Clinicians Estimate Cardiac Function in Critically Ill Patients: Prospective Observational Cohort Study. *JMIR Medical Informatics*, *7*(4), e15358. https://doi.org/10.2196/15358

Lorca, J. C., & Águila, L. C. (2024). Inferencia Bayesiana en el proceso de diagnóstico clínico: un enfoque docente para la toma de decisiones. *Revista Chilena de Infectología*, *41*(6), 762-768. https://doi.org/10.4067/s0716-10182024000600168

Pek, T., & Van Zandt, T. (2019). Frequentist and Bayesian approaches to to data analysis: Evaluation and estimation. *SageJournals*, *19*(1). https://doi.org/10.1177/1475725719874542

Ramos-Vera, C. A. (2021). El uso del factor Bayes en la investigación clínica de cardiología. *Revista Española de Cardiología*, *74*(7), 641-642. https://doi.org/10.1016/j.recesp.2021.01.013

Real Academia Española. (2026). *Diccionario de la lengua española*. https://dle.rae.es

Rodríguez-Escudero, J. P., López-Jiménez, F., & Trejos-Gutiérrez, J. (2012). Cardiología "basada en la evidencia": aplicaciones prácticas de la epidemiología. IV. Modelos de predicción de riesgo cardiovascular. *Arch. Cardiol. Méx*, *82*(1). https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-99402012000100011

Ulianova, S. (2019). *Cardiovascular Disease Dataset*. https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset

World Heart Federation. (2023). *Enfermedades cardiovasculares (ECV)*. https://world-heart-federation.org/es/what-is-cvd/